


# TP-Perceptron

## 1. Algorithme du perceptron pour la classification binaire

1.1. Commençons par générer et afficher un jeu de données en utilisant la fonction `generateData` fournie :




1.2.

Alors, voilà comment ça marche :

Au début, on part d'un vecteur de poids  $w$  initialisé à zéro. Ensuite, on répète une boucle : à chaque tour, on regarde chaque exemple de données. Si un point est mal classé (par exemple, il devrait être rouge mais le modèle le voit comme bleu), on ajuste  $w$  pour corriger l'erreur. On s'arrête seulement quand tous les exemples sont bien classés (plus d'erreurs !). Pour montrer le résultat :


- Les points bleus sont ceux de la classe -1,
- Les points rouges, la classe 1,

- La ligne noire, c'est la frontière (hyperplan) que le perceptron a apprise pour séparer les deux groupes.




1.3.


Si les données sont bien linéairement séparables, l'erreur doit être proche de 0%. Sinon, l'erreur peut être plus élevée.



1.4.

Maintenant, passons à l'extension avec un biais, c'est-à-dire le cas où les données ne sont pas séparables par une droite passant par l'origine. Je modifie la fonction de génération des données ([generateData2](#)) pour qu'elles soient toujours séparables, mais par une droite qui ne passe pas par l'origine, puis je complète les échantillons en ajoutant une coordonnée constante 1 pour prendre en compte le biais.






## 2. Perceptron `a noyau

### 2.1.

Je commence par la génération de données non linéairement séparables avec la fonction [generateData3](#) :



2.2.

Je définit un plongement polynomial pour transformer les données :

```
def polynomial_feature_mapping(X):
    X_poly = np.c_[np.ones(X.shape[0]), X[:, 0], X[:, 1], X[:, 0]**2, X[:, 0] * X[:, 1], X[:, 1]**2]
    return X_poly

# Transformation des données
X3_poly = polynomial_feature_mapping(X3)
```

2.3.

Le perceptron standard stocke un vecteur de poids  $w$ , mais avec un noyau, on stocke plutôt un ensemble de coefficients  $\alpha$  associés aux échantillons support

2.4.

Pour prédire la classe d'un nouveau point, on utilise :


$$f(x) = \sum_{i \in V} \alpha_i y_i k(x_i, x)$$

Anass EZZINE

4A FISA

Département informatique

On remarque que les données non séparables linéairement et que la frontière de séparation est courbée pour mieux séparer les classes:



2.5.

On peut aussi tester un noyau Gaussien sur plusieurs valeurs sigma et on peut voir comment la séparation change pour chaque valeur :

```
def kernel_gaussian(x, y, sigma=1):  
    return np.exp(-np.linalg.norm(np.array(x) - np.array(y))**2 / (2 * sigma**2))  
  
# Entraînement du perceptron avec noyau Gaussien  
alphas_gauss, support_vectors_gauss = perceptron_kernel(X3, Y3, kernel_gaussian)
```


```
# Expérimentation avec différents sigma
for sigma in [0.2, 0.5, 1, 2, 5]:
    alphas_gauss, support_vectors_gauss = perceptron_kernel(X3, Y3, lambda x, y: kernel_gaussian(x, y, sigma))

plt.figure(figsize=(8, 6))
plt.scatter(X3[Y3 == -1, 0], X3[Y3 == -1, 1], color='blue', marker='o', label='Classe -1')
plt.scatter(X3[Y3 == 1, 0], X3[Y3 == 1, 1], color='red', marker='x', label='Classe 1')


# Tracé de la frontière de séparation
res = 100
x_vals = np.linspace(-1.5, 1.5, res)
y_vals = np.linspace(-1.5, 1.5, res)


for x in range(res):
    for y in range(res):
        if abs(f_from_kernel(alphas_gauss, support_vectors_gauss, lambda x, y: kernel_gaussian(x, y, sigma), [x_vals[x], y_vals[y]])) < 0.01:
            plt.plot(x_vals[x], y_vals[y], 'kx', markersize=2) # Points proches de la frontière


plt.legend()
plt.title(f"Perceptron à Noyau Gaussien ( $\sigma={sigma}$ )")
plt.show()
```














### 3. Exercice

#### 3.1.

Cette fonction mesure la précision d'un modèle avancé en s'appuyant sur plusieurs éléments : les coefficients (`coeffs`), un ensemble de supports (`support_set`) et une fonction `k`, qui peut agir comme un noyau dans une version améliorée du perceptron. Elle détermine la classe d'un échantillon en combinant linéairement les supports, puis applique la fonction `np.sign()` pour produire une classification binaire :

```
def score(S, coeffs, support_set, k):  
    correct_predictions = 0  
    total_samples = len(S)  
  
    for x, label in S:  
        prediction = np.sign(sum(coeff * k(support, x) for coeff, support in zip(coeffs, support_set)))  
        if prediction == label:  
            correct_predictions += 1  
  
    return correct_predictions / total_samples
```

#### 3.2.

